

Olist 데이터셋 인사이트 도출 채점 기준

무엇을 보고 어떻게 점수를 매기는지 전부 공개합니다. 쓰기 전에 한 번, 내기 전에 한 번 읽어보세요.

이 과제는 쿼리의 화려함을 보지 않습니다. 테이블 2개만 조인해도 최고 단계가 나올 수 있고, 5개 테이블에 윈도우 함수를 써도 1단계가 될 수 있습니다. 보는 것은 두 가지입니다 — 어떤 질문을 세웠는가, 그리고 그 질문에 답하려고 무엇을 고민했는가.

0 제출물과 배점

네 가지를 제출합니다. 앞의 세 개가 서로 어긋나면 마지막이 아무리 좋아도 분석이 성립하지 않습니다.

- | | |
|---------|--|
| ① 질문 | 무엇을 알아보려 했는지 한 문장. <i>이 자체가 채점 항목이므로 반드시 적습니다.</i> |
| ② 쿼리 | BigQuery에서 실제로 돌린 SQL |
| ③ 실행 결과 | 결과 표를 그대로 복사. 행이 많으면 상위 10~20행 |
| ④ 인사이트 | 무엇을 발견했고, 왜 그렇게 보며, 그래서 무엇을 하자는 것인지 |

20

질문의
질

25

쿼리 설계
판단

15

근거 사슬
정합성

20

분석의
깊이

12

비즈니스
해석

8

액션
제안

60점 이상이면 제출 권장 수준입니다. 점수는 성적이 아니라 “이 정도면 내도 되겠다”는 신호로만 쓰세요.

정합성에 배점을 많이 주지 않는 이유. 질문·쿼리·결과·주장이 어긋나지 않는 것은 잘한 것이 아니라 분석이 성립하기 위한 최소 조건입니다. 그래서 15점입니다. “시시한 질문을 정확하게 답한” 제출물이 고득점하지 않도록, 점수는 **질문의 질(20점)** 과 **쿼리 설계 판단(25점)** 에서 갑니다.

1 질문의 질

20점

정해진 문제가 없는 과제이므로 무엇을 물었는지가 출발점입니다. 실력 차이가 가장 크게 드러나는 지점이기도 합니다. 답하기 전에 질문이 좋아야 합니다.

단계	점수	기준
----	----	----

1	0-5	질문이 없다. 또는 이 데이터로 답할 수 없다. 또는 답이 이미 자명하다
2	6-11	답할 수 있고 자명하지도 않지만 막연하다 . 대상이나 비교 기준이 특정되지 않음
3	12-16	대상 · 비교축 · 판단 기준이 특정됨 . 답이 나오면 무엇을 알게 되는지가 분명함
4	17-20	위에 더해 답이 어느 쪽으로 나와도 의미가 있는 질문 . 통념을 검증하거나, 반례가 있을 만한 곳을 찌름

같은 주제, 네 단계의 질문

단계	질문
1	“주문이 가장 많은 주는 어디인가” 집계 한 번으로 끝나고, 알아도 할 일이 없습니다.
2	“배송이 리뷰에 영향을 주는가” 무엇을 ‘배송’으로, 무엇을 ‘영향’으로 볼지 정해지지 않았습니다.
3	“약속일보다 3일 이상 늦게 도착한 주문은 정시 도착 주문보다 리뷰 평균이 낮은가” 대상·비교축·판단 기준이 모두 특정됐습니다.
4	“배송 지연이 리뷰를 낮춘다면, 지연에 관대한 카테고리도 있는가 . 가구처럼 원래 오래 걸린다고 기대되는 상품군은 같은 지연에도 리뷰가 덜 떨어지지 않을까” 답이 ‘그렇다’여도 ‘아니다’여도 알게 되는 것이 있습니다.

2 쿼리 설계 판단

25점

기법의 개수가 아니라 **선택의 흔적**을 봅니다. JOIN을 더 붙인다고, 윈도우 함수를 쓴다고 점수가 오르지 않습니다. **배점이 가장 큰 항목**입니다.

단계	점수	기준
1	0-6	실행 불가하거나 스키마에 없는 컬럼 사용. 또는 질문에 답할 수 없는 구조
2	7-13	실행되고 답도 나오지만 기본값에 머물. 아래 판단 지점이 하나도 다뤄지지 않음
3	14-19	아래 판단 지점 중 둘 이상 을 의도적으로 처리함
4	20-25	위에 더해 왜 그렇게 선택했는지 인사이트나 주석에 밝힘. 다른 선택을 했다면 결과가 어떻게 달라지는지까지 쓰면 확실한 4단계

다섯 개의 판단 지점

지점	스스로에게 물어볼 것
모집단 정의	<code>order_status</code> 를 어떻게 다룰 것인가. <code>delivered</code> 만 볼 것인가, <code>canceled</code> 만 뺄 것인가. 내 질문이 묻는 “주문”은 어디까지인가

JOIN 종류	LEFT인가 INNER인가. 이걸 문법 취향이 아니라 “ 한쪽에 없는 행을 남길 것인가 ”라는 질문입니다. 예: 리뷰를 안 쓴 주문도 분모에 넣을 것인가? 넣어야 하면 LEFT, 리뷰가 있는 주문만 보는 게 맞으면 INNER. 어느 쪽이든 의도한 것이어야 합니다
집계 단위	결과의 행 하나가 무엇인가 — 주문 1건? 주문상품 1건? 고객 1명? <code>COUNT(DISTINCT order_id)</code> 와 <code>COUNT(*)</code> 는 다른 질문에 답합니다
고객 식별자	<code>customer_id</code> (주문마다 새로 생김) 와 <code>customer_unique_id</code> (사람) 중 내 질문에 맞는 것은 무엇인가
NULL 처리	배송되지 않아 <code>order_delivered_customer_date</code> 가 비어 있는 주문을 어떻게 할 것인가. 평균에서 조용히 빠지게 둘 것인가, 명시적으로 뺄 것인가

4단계로 가는 가장 쉬운 길: 인사이트 본문에 한 줄만 더 쓰면 됩니다. — “취소·미배송 주문은 배송 기간을 썰 수 없어 delivered 만 남겼습니다. 이걸 포함하면 표본이 약 3% 늘지만 지연일 계산이 불가능해집니다.”

3 근거 사슬 정합성

15점

질문 → 쿼리 → 결과 → 주장이 한 줄로 이어지는지 봅니다. 잘하면 받는 점수가 아니라 **어긋나면 잃는 점수**입니다. 그래서 배점을 낮게 뒀습니다. 대신 아래 **연쇄 차단**이 걸립니다.

단계	점수	기준
1	0-4	사슬이 끊김. 질문이 없거나, 쿼리가 질문과 다른 것을 계산하거나, 주장이 결과에 없는 내용임
2	5-8	질문과 쿼리가 대체로 맞지만 범위가 어긋남 (아래 표 참고)
3	9-12	질문·쿼리·결과·주장이 일치하고, 인용한 수치가 붙여넣은 결과에 실제로 있음
4	13-15	위에 더해 비교 기준선 (전체 평균·다른 세그먼트·이전 기간)을 제시해 “이 숫자가 큰지 작은지”에 답함

연쇄 차단. 이 항목이 1단계면 **분석의 깊이와 비즈니스 해석도 각각 2단계를 넘지 못합니다**(최대 11점 / 7점). 질문에 답하지 못하는 쿼리에서 나온 깊이와 해석은 근거가 없기 때문입니다. 배점이 15점으로 낮아도 어긋남의 대가는 작지 않습니다.

2단계로 내려가는 전형적인 어긋남

이렇게 물어놓고	이렇게 세면 다른 걸 센 것
“재구매 고객”	<code>customer_id</code> 로 센. 이 컬럼은 주문마다 새로 생기므로 재구매가 잡히지 않습니다. 사람 단위는 <code>customer_unique_id</code>
“배송 지연”	<code>canceled</code> · <code>unavailable</code> 주문까지 포함. 배송된 적 없는 주문의 지연은 의미가 없습니다
“주문당 평균”	<code>order_items</code> 단위로 센. 한 주문에 상품이 3개면 그 주문이 3번 계산됩니다
“카테고리별”	INNER JOIN 때문에 상품 정보가 없는 주문이 조용히 빠짐. 분모가 달라집니다

“전체 주문 중”

`order_items` 와 조인. 항목이 하나도 없는 주문 **775건**이 사라집니다

4 분석의 깊이

20점

단계	점수	기준
1	0-5	한 가지 차원의 순위 나열에서 끝남 (“SP주 주문이 가장 많다”)
2	6-11	두 변수의 관계를 보거나, 시간에 따른 변화를 봄
3	12-16	세그먼트를 나눠 비교하거나, 결과를 왜곡할 수 있는 요인을 고려함
4	17-20	위에 더해 반대 가설 을 세워 데이터로 검증하거나 배제함

반대 가설의 예: “지연된 주문의 리뷰가 낮은 게 아니라, 원래 리뷰가 낮은 카테고리가 배송이 오래 걸리는 것일 수도 있다” → 카테고리를 고정하고 다시 본다.

5 비즈니스 해석

12점

단계	점수	기준
1	0-3	현상 서술만 있음. “그래서 무엇인지”가 없음
2	4-7	왜 그런지 가설을 제시함
3	8-10	가설이 데이터 특성이나 이커머스 도메인 맥락과 연결됨
4	11-12	인과를 단정하지 않고, 이 해석이 틀릴 수 있는 조건 을 함께 밝힘

6 액션 제안

8점

단계	점수	기준
1	0-2	없거나 “개선이 필요하다” 수준
2	3-5	방향은 있으나 대상·기준이 불명확
3	6-8	대상·기준·확인 방법이 구체적

단계	예시
1	“배송을 개선하자”
2	“배송 지연이 심한 주(state)를 관리하자”

3

“실제 배송이 예상일보다 평균 6일 이상 늦는 4개 주에 대해 예상 배송일을 재산정하고, 3개월 뒤 해당 주의 `review_score` 평균이 오르는지 확인한다”

아래 수치는 기준 설명을 위해 지어낸 예시이며 실제 Olist 데이터의 값이 아닙니다. 형식과 사고 과정만 참고하세요.

약한 제출물 · 합계 34점

질문

배송이 늦으면 리뷰가 안 좋은가?

쿼리

```
SELECT
  CASE WHEN o.order_delivered_customer_date > o.order_estimated_delivery_date
    THEN '지연' ELSE '정시' END AS delay,
  AVG(r.review_score) AS avg_score
FROM olist_raw.orders AS o
JOIN olist_raw.order_reviews AS r ON o.order_id = r.order_id
GROUP BY delay;
```

결과

지연 2.6 / 정시 4.3

인사이트

지연되면 평균 리뷰가 낮다. 배송을 개선해야 한다.

질문의 질 **8**(2단계 · 무엇을 지연으로, 무엇을 '안 좋음'으로 볼지 미정) · 쿼리 설계 **10**(2단계 · 판단 지점 미처리) · 근거 사슬 **7**(2단계 · 취소·미배송을 다루지 않았고 비교 기준선 없음) · 깊이 **4**(1단계) · 해석 **3**(1단계) · 액션 **2**(1단계)

질문

배송이 예상일보다 늦게 도착한 주문은 정시 도착 주문보다 리뷰 점수가 낮은가? 낮다면 며칠부터 두드러지는가?

쿼리

```
WITH delivered AS (
    -- 배송 완료 건만: 취소·미배송은 지연일을 켈 수 없음
    SELECT
        order_id,
        DATE_DIFF(DATE(order_delivered_customer_date),
            DATE(order_estimated_delivery_date), DAY) AS delay_days
    FROM olist_raw.orders
    WHERE order_status = 'delivered'
        AND order_delivered_customer_date IS NOT NULL
)
SELECT
    CASE WHEN d.delay_days <= 0 THEN '정시 이내'
        WHEN d.delay_days <= 5 THEN '1-5일 지연'
        WHEN d.delay_days <= 10 THEN '6-10일 지연'
        ELSE '11일 이상 지연' END AS delay_bucket,
    COUNT(DISTINCT d.order_id) AS order_cnt,      -- 주문 단위 (아이템 아님)
    ROUND(AVG(r.review_score), 2) AS avg_score
FROM delivered AS d
JOIN olist_raw.order_reviews AS r ON d.order_id = r.order_id  -- 리뷰 있는 주문만
GROUP BY delay_bucket
ORDER BY MIN(d.delay_days);
```

결과 (예시)

구간	주문 수	평균 리뷰
정시 이내	88,120	4.28
1-5일 지연	4,930	3.41
6-10일 지연	1,780	2.55
11일 이상 지연	1,640	1.92

인사이트

전체 평균 리뷰는 **4.09**인데, 1-5일 지연 구간은 3.41로 이미 평균을 밑돕니다. 다만 하락이 가파른 지점은 **6일부터**, 2.55까 지 떨어져 정시 대비 1.7점 낮습니다. “늦으면 리뷰가 낮다”가 아니라 “**6일을 넘기면 급락한다**”가 정확한 표현입니다. 약속 대비 편차가 임계치를 넘는 순간 고객이 이를 ‘사고’로 인식하는 것으로 보입니다.

설계 선택: 지연일을 켈 수 없는 취소·미배송 건은 제외했습니다. 리뷰를 쓰지 않은 주문도 INNER JOIN으로 뺐는데, 리뷰 점수가 종속변수이므로 없는 행은 분석 대상이 아니기 때문입니다. 다만 이 선택 때문에 **불만이 커서 아예 리뷰를 안 쓴 고객**이 빠졌을 수 있어, 실제 지연의 악영향은 위 수치보다 클 가능성이 있습니다.

반대 가설 검증: 배송이 오래 걸리는 카테고리가 원래 리뷰가 낮은 것일 수 있어 가구·대형가전을 제외하고 다시 집계했으나 구간별 격차는 유지되었습니다.

액션: 6일 이상 지연 비중이 높은 상위 4개 주에 대해 예상 배송일을 현재보다 보수적으로 재산정하고, 3개월 뒤 해당 주의 지연 구간 분포와 평균 리뷰가 개선되는지 확인합니다.

질문의 질 **17**(4단계 · 대상·비교축이 특정되고, “며칠부터”는 답이 어느 쪽이어도 의미가 있음) · 쿼리 설계 **22**(4단계 · 모집단·집계 단위·JOIN 종류를 처리하고 이유를 밝힘) · 근거 사슬 **13**(4단계 · 전체 평균 기준선 제시) · 깊이 **17**(4단계 · 반대 가설을 세워 데이터로 배제함) · 해석 **10**(3단계) · 액션 **7**(3단계)

두 제출물의 쿼리 난이도 차이는 크지 않습니다. 강한 쪽도 테이블 2개를 조인했을 뿐입니다. 차이는 **질문을 좁힌 것**(“늦으면 안 좋은가” → “며칠부터 두드러지는가”), `WHERE order_status = 'delivered'` 한 줄, 구간을 나눈 판단, 그리고 **왜 그렇게 했는지 적은 세 문장**에서 나왔습니다. 52점 차이의 상당 부분은 **질문을 다시 쓴 데서** 나왔습니다.

8 제출 전 자가 점검

항목	스스로 확인
질문	내 질문은 집계 한 번으로 끝나는 것이 아닌가? 답을 알면 무엇을 할 수 있는가?
질문	대상·비교축·판단 기준이 문장 안에 들어 있는가?
질문	답이 반대로 나와도 쓸 말이 있는가? 한쪽 답만 기대하고 있다면 질문을 다시 보세요
근거 사슬	내 쿼리를 말로 옮기면 무엇을 세는 문장이 되는가? 그게 내가 적은 질문과 같은가?
근거 사슬	인사이트에 쓴 숫자가 붙여넣은 결과 표에 실제로 있는가?
근거 사슬	이 숫자가 큰 건지 작은 건지 알려주는 비교 대상이 있는가?
쿼리 설계	<code>order_status</code> 를 한 번이라도 생각했는가?
쿼리 설계	LEFT / INNER 선택이 의도한 것인가, 그냥 쓴 것인가?
쿼리 설계	결과와 행 하나가 무엇 단위인지 한 마디로 말할 수 있는가?
쿼리 설계	그 선택의 이유를 인사이트에 한 줄이라도 적었는가?
깊이	순위 나열에서 끝나지 않았는가?
해석	“그래서 무엇”에 답했는가? 틀릴 수 있는 조건을 밝혔는가?
액션	대상·기준·확인 방법이 들어 있는가?

9 참고: 테이블과 데이터 함정

olist_raw 테이블

테이블	주요 컬럼
<code>orders</code>	order_id, customer_id, order_status, order_purchase_timestamp, order_approved_at, order_delivered_carrier_date, order_delivered_customer_date, order_estimated_delivery_date
<code>order_items</code>	order_id, order_item_id, product_id, seller_id, shipping_limit_date, price, freight_value
<code>order_payments</code>	order_id, payment_sequential, payment_type, payment_installments, payment_value

<code>order_reviews</code>	<code>review_id</code> , <code>order_id</code> , <code>review_score</code> , <code>review_comment_title</code> , <code>review_comment_message</code> , <code>review_creation_date</code> , <code>review_answer_timestamp</code>
<code>customers</code>	<code>customer_id</code> , <code>customer_unique_id</code> , <code>customer_zip_code_prefix</code> , <code>customer_city</code> , <code>customer_state</code>
<code>sellers</code>	<code>seller_id</code> , <code>seller_zip_code_prefix</code> , <code>seller_city</code> , <code>seller_state</code>
<code>products</code>	<code>product_id</code> , <code>product_category_name</code> , <code>product_name_lenght</code> , <code>product_description_lenght</code> , <code>product_photos_qty</code> , <code>product_weight_g</code> , <code>product_length_cm</code> , <code>product_height_cm</code> , <code>product_width_cm</code>
<code>geolocation</code>	<code>geolocation_zip_code_prefix</code> , <code>geolocation_lat</code> , <code>geolocation_lng</code> , <code>geolocation_city</code> , <code>geolocation_state</code>
<code>product_category_name_translation</code>	<code>product_category_name</code> , <code>product_category_name_english</code>

미리 알려주는 함정

- `orders` 와 `customers` 는 `customer_id` 로 1:1 매칭됩니다. 재구매를 세려면 `customer_unique_id` 를 써야 합니다.
- `order_items` 에 행이 하나도 없는 주문이 **775건** 있습니다. 이 테이블과 조인하는 순간 조용히 사라집니다.
- 한 주문에 `order_item_id` 가 여러 개 붙을 수 있습니다. 주문 단위 집계와 상품 단위 집계를 섞으면 수치가 부풀려집니다.
- `order_status` 에는 `delivered` 외에 `canceled`, `unavailable`, `shipped` 등이 섞여 있습니다.
- 데이터 기간은 2016-09 ~ 2018-10 입니다. 양 끝 구간은 데이터가 얇으니 시계열을 볼 때 주의하세요.

셀프체크 도구 — 제출 전에 이 기준으로 자동 채점을 받아볼 수 있습니다. 항목별로 지금 몇 단계인지, 한 단계 올리려면 무엇을 해야 하는지 알려줍니다. 여러 번 고쳐서 다시 돌려도 됩니다. 링크와 접속 코드는 공지를 참고하세요.